

# Dẫn nhập về suy luận Bayes (Introduction to Bayesian Inference)

VietAI Guest Lecture

2020

Nguyễn Sỹ Khánh

# Mục tiêu

- Giới thiệu phương pháp suy luận Bayes - cách tư duy xác suất
- Giúp khán giả hiểu được trực giác Bayes
- Giới thiệu các ứng dụng của suy luận Bayes trong Machine Learning

# Thomas Bayes (/beɪz/)



- Nhà thống kê học, triết gia và mục sư người Anh
- Sống ở thế kỉ 18 (1701-1761)

Nguồn: Wikipedia

# Nhắc lại về xác suất: quy tắc cộng và quy tắc nhân

Quy tắc nhân:

$$p(a, b, c) = p(a)p(b|a)p(c|b, a)$$

Quy tắc cộng (**rời rạc**):

$$p(a) = \sum_b p(a, b) = \sum_b p(a|b)p(b)$$

Quy tắc cộng (**liên tục**):

$$p(a) = \int_b p(a, b)db$$

Mọi phương trình trong suy luận Bayes đều là hệ quả của 2 quy tắc trên.

# Định lý Bayes

Tính chất của xác suất có điều kiện: xét 2 sự kiện A và B

$$p(A|B) = \frac{p(B|A)p(A)}{p(B)}$$

# Suy luận Bayes

Xác suất có điều kiện: tham số mô hình  $\theta$  và dữ liệu  $D$

$$p(\theta|\mathcal{D}) = \frac{p(\mathcal{D}|\theta)p(\theta)}{p(\mathcal{D})}$$

# Suy luận Bayes

Xác suất có điều kiện: tham số mô hình  $\theta$  và dữ liệu  $D$ .

$$p(\theta|D) = \frac{p(D|\theta)p(\theta)}{p(D)}$$


Biểu thức là hàm theo  $\theta$ . Dữ liệu  $D$  là duy nhất và bất biến.

# Suy luận Bayes

Xác suất có điều kiện: tham số mô hình  $\theta$  và dữ liệu  $D$

$$p(\theta|D) = \frac{p(D|\theta)p(\theta)}{p(D)}$$

Xác suất tiên nghiệm  
(prior)



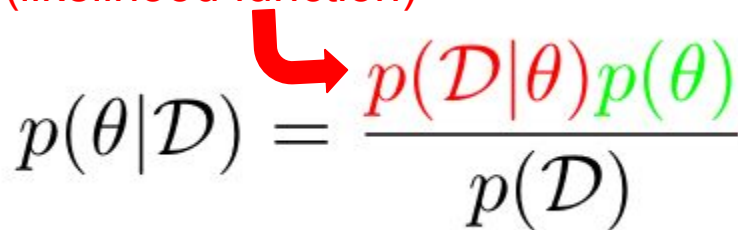


# Suy luận Bayes

Xác suất có điều kiện: tham số mô hình  $\theta$  và dữ liệu  $D$

Hàm khả năng  
(likelihood function)

Xác suất tiên nghiệm  
(prior)

$$p(\theta|D) = \frac{p(D|\theta)p(\theta)}{p(D)}$$


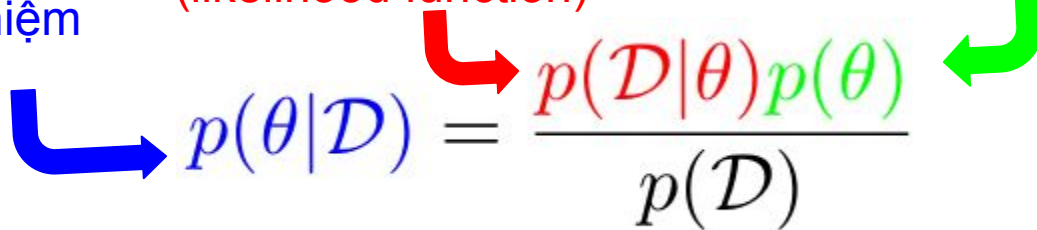
# Suy luận Bayes

Xác suất có điều kiện: tham số mô hình  $\theta$  và dữ liệu  $D$

Xác suất hậu nghiệm  
(posterior)

Hàm khả năng  
(likelihood function)

Xác suất tiên nghiệm  
(prior)



A diagram illustrating the components of Bayes' theorem. A blue arrow points from the text 'Xác suất hậu nghiệm (posterior)' to the term  $p(\theta|D)$  in the formula. A red arrow points from the text 'Hàm khả năng (likelihood function)' to the term  $p(D|\theta)$  in the formula. A green arrow points from the text 'Xác suất tiên nghiệm (prior)' to the term  $p(\theta)$  in the formula. The formula is 
$$p(\theta|D) = \frac{p(D|\theta)p(\theta)}{p(D)}$$

# Suy luận Bayes

Xác suất có điều kiện: tham số mô hình  $\theta$  và dữ liệu  $D$

Xác suất hậu nghiệm (posterior)

Hàm khả năng (likelihood function)

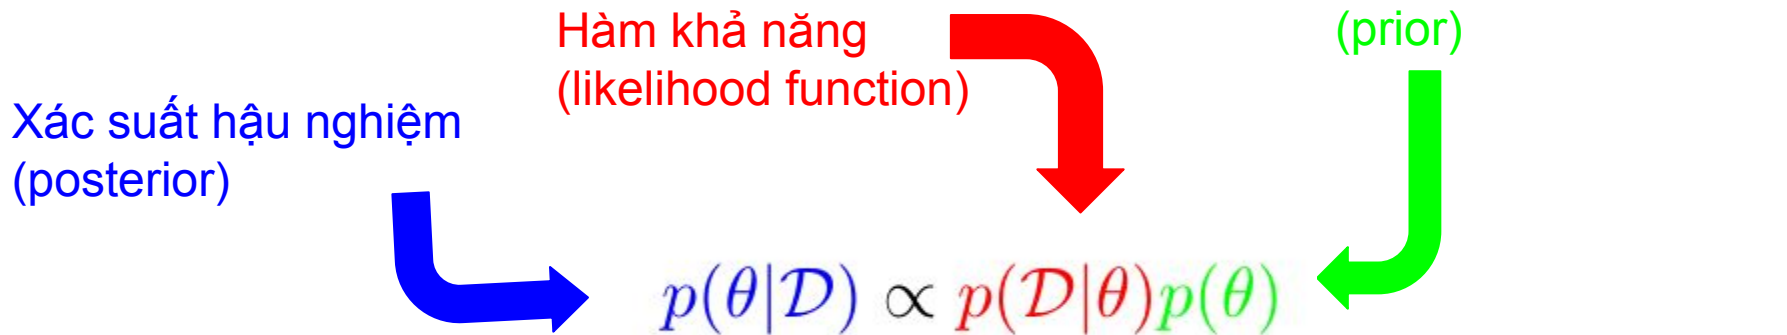
Xác suất tiên nghiệm (prior)

Chứng cứ mô hình (model evidence)

$$p(\theta|D) = \frac{p(D|\theta)p(\theta)}{p(D)}$$
A diagram illustrating Bayes' theorem. The equation  $p(\theta|D) = \frac{p(D|\theta)p(\theta)}{p(D)}$  is centered. A blue arrow points from the label 'Xác suất hậu nghiệm (posterior)' to the term  $p(\theta|D)$  on the left. A red arrow points from the label 'Hàm khả năng (likelihood function)' to the term  $p(D|\theta)$  in the numerator. A green arrow points from the label 'Xác suất tiên nghiệm (prior)' to the term  $p(\theta)$  in the numerator. A black arrow points from the label 'Chứng cứ mô hình (model evidence)' to the term  $p(D)$  in the denominator.

# Suy luận Bayes

Xác suất có điều kiện: tham số mô hình  $\theta$  và dữ liệu  $D$




# Ví dụ 1: Tung đồng xu

Xét một đồng xu 2 mặt.

- Nghi vấn: đồng xu bị gài (ăn gian)  $\Leftrightarrow$  xác suất ra mặt ngửa không phải  $1/2$
- Làm sao để kiểm định nghi vấn này?



nguồn: thinglink.com



nguồn:  
<http://www.win-vector.com/blog/2015/04/i-still-think-you-can-manufacture-an-unfair-coin/>

# Ví dụ 1: Tung đồng xu

Xét một đồng xu 2 mặt.

- Nghi vấn: đồng xu bị gài (ăn gian)  $\Leftrightarrow$  xác suất ra mặt ngửa không phải  $1/2$
- Làm sao để kiểm định nghi vấn này?  
 $\Rightarrow$  LẤY MẪU/SAMPLE

# Ví dụ 1: Tung đồng xu

Xét một đồng xu 2 mặt. Khi tung thử 3 lần, đều ra mặt ngửa.

Gọi  $\theta$  là xác suất ra mặt ngửa.

Hàm khả năng:

$$p(\mathcal{D}|\theta) = \theta^3$$

$\Rightarrow \theta_{\text{maximum\_likelihood}} = 1$

$\Rightarrow$  đồng xu có xác suất  $P(\text{Ngửa}) = 1$

$\Rightarrow$  Luôn ra mặt ngửa - Có hợp lý không?

# Ví dụ 1: Tung đồng xu


Xét một đồng xu 2 mặt. Khi tung thử 3 lần, đều ra mặt ngửa.

Tiên nghiệm: **phân bố chuẩn** với trung bình = 0.5

$$p(\theta) = \mathcal{N}(\theta|0.5, \sqrt{0.05})$$

Hàm khả năng:

$$p(\mathcal{D}|\theta) = \theta^3$$



đồ thị tạo ở: <https://www.desmos.com/calculator>  
interactive:  
<https://www.desmos.com/calculator/qpne2g7emb>




# Ví dụ 1: Tung đồng xu

Xét một đồng xu 2 mặt. Khi tung thử 3 lần, đều ra mặt ngửa.

Hậu nghiệm:

$$p(\mathcal{D}|\theta) \propto \mathcal{N}(\theta|0.5, \sqrt{0.05})p(\mathcal{D}|\theta)$$




đồ thị tạo ở: <https://www.desmos.com/calculator>

# Ví dụ 1: Tung đồng xu

Xét một đồng xu 2 mặt. Khi tung thử 3 lần, đều ra mặt ngửa.

Hậu nghiệm:



đồ thị tạo ở: <https://www.desmos.com/calculator>

Ước tính giá trị của  $\theta$ : cực đại hậu nghiệm (maximum a posteriori)  $\Rightarrow \theta = 0.711$

# Ví dụ 1: Tung đồng xu

Xét một đồng xu 2 mặt. Khi tung thử 3 lần, đều ra mặt ngửa.

Kết quả:  $\theta$  là xác suất ra mặt ngửa

- Cực đại hàm khả năng:  $\theta = 1$
- Suy luận Bayes:  $\theta = 0.711$

# Ví dụ 1: Tung đồng xu

Trường hợp khác: tung 10 lần ra 7 lần ngửa, 3 lần sấp

Likelihood:  $p(\mathcal{D}|\theta) = \theta^7(1 - \theta)^3$

Kết quả:  $\theta$  là xác suất ra mặt ngửa

- Cực đại hàm khả năng:  $\theta = 0.7$
- Suy luận Bayes:  $\theta = ???$

# Ví dụ 1: Tung đồng xu

Tiếp tục tung đồng xu thêm  $n$  lần để thu thập thêm dữ liệu.

Quá trình suy luận có thể tiếp diễn...

- tiên nghiệm mới = hậu nghiệm cũ
- Áp dụng định luật Bayes với **tiên nghiệm mới** và **hàm khả năng mới**
- Cập nhật hậu nghiệm với từng điểm/tập dữ liệu mới

Khi lượng dữ liệu tăng lên, ảnh hưởng của phân bố tiên nghiệm ban đầu giảm dần.

## Ví dụ 2: Linear regression

Bài toán hồi quy tuyến tính cho một tập dữ liệu  $D = \{\mathbf{X}, \mathbf{y}\}$

## Ví dụ 2: Linear regression

Bài toán hồi quy tuyến tính cho một tập dữ liệu  $D = \{\mathbf{X}, \mathbf{y}\}$

Cần tìm một bộ trọng số  $\mathbf{w}$  để ánh xạ  $\mathbf{x}$  sang  $\mathbf{y}$

$$y = \mathbf{w}^T \mathbf{x}$$

## Ví dụ 2: Linear regression

Bài toán hồi quy tuyến tính cho một tập dữ liệu  $D = \{\mathbf{X}, \mathbf{y}\}$

Cần tìm một bộ trọng số  $\mathbf{w}$  để ánh xạ  $\mathbf{x}$  sang  $\mathbf{y}$

$$y = \mathbf{w}^T \mathbf{x}$$

Dùng mô hình nhiễu tín hiệu để chuyển thành bài toán xác suất

$$y = \mathbf{w}^T \mathbf{x} + \epsilon$$



$$p(y|\mathbf{x}, \mathbf{w}, \epsilon) = \mathcal{N}(\mathbf{w}^T \mathbf{x}, \sigma^2)$$

$$p(\epsilon) = \mathcal{N}(0, \sigma^2)$$



## Ví dụ 2: Linear regression

Bài toán hồi quy tuyến tính cho một tập dữ liệu  $D = \{\mathbf{X}, \mathbf{y}\}$

Hàm khả năng trở thành:  $p(\mathcal{D}|\mathbf{w}) = p(\mathbf{y}|\mathbf{w}, \mathbf{x}, \sigma) = \prod_{i=1}^N \mathcal{N}(\mathbf{w}^T \mathbf{x}_i, \sigma^2)$

## Ví dụ 2: Linear regression

Bài toán hồi quy tuyến tính cho một tập dữ liệu  $D = \{\mathbf{X}, \mathbf{y}\}$

Hàm khả năng trở thành: 
$$p(\mathcal{D}|\mathbf{w}) = p(\mathbf{y}|\mathbf{w}, \mathbf{x}, \sigma) = \prod_{i=1}^N \mathcal{N}(\mathbf{w}^T \mathbf{x}_i, \sigma^2)$$

Lấy log để tránh underflow khi tính toán xác suất - hàm **log likelihood**:

$$\ln p(\mathcal{D}|\mathbf{w}) = \sum_{i=1}^N \ln \frac{1}{\sigma \sqrt{2\pi}} \exp\left(-\frac{(y_i - \mathbf{w}^T \mathbf{x})^2}{2\sigma^2}\right)$$

$$\ln p(\mathcal{D}|\mathbf{w}) = N \ln \frac{1}{\sigma} - \frac{N}{2} \ln(2\pi) - \frac{1}{2\sigma^2} \sum_{i=1}^N (y_i - \mathbf{w}^T \mathbf{x})^2$$

## Ví dụ 2: Linear regression

Bài toán hồi quy tuyến tính cho một tập dữ liệu  $D = \{\mathbf{X}, \mathbf{y}\}$

Hàm khả năng trở thành:  $p(\mathcal{D}|\mathbf{w}) = p(\mathbf{y}|\mathbf{w}, \mathbf{x}, \sigma) = \prod_{i=1}^N \mathcal{N}(\mathbf{w}^T \mathbf{x}_i, \sigma^2)$

Lấy log để tránh underflow khi tính toán xác suất - hàm **log likelihood**:

$$\ln p(\mathcal{D}|\mathbf{w}) = \sum_{i=1}^N \ln \frac{1}{\sigma \sqrt{2\pi}} \exp\left(-\frac{(y_i - \mathbf{w}^T \mathbf{x})^2}{2\sigma^2}\right)$$

$$\ln p(\mathcal{D}|\mathbf{w}) = N \ln \frac{1}{\sigma} - \frac{N}{2} \ln(2\pi) - \frac{1}{2\sigma^2} \sum_{i=1}^N (y_i - \mathbf{w}^T \mathbf{x})^2$$

## Ví dụ 2: Linear regression

Bài toán hồi quy tuyến tính cho một tập dữ liệu  $D = \{\mathbf{X}, \mathbf{y}\}$

Hàm khả năng cao  $\Leftrightarrow$  xác suất cao mô hình khớp với dữ liệu

Để cực đại hóa hàm khả năng:

$$\ln p(D|\mathbf{w}) = N \ln \frac{1}{\sigma} - \frac{N}{2} \ln(2\pi) - \frac{1}{2\sigma^2} \sum_{i=1}^N (y_i - \mathbf{w}^T \mathbf{x})^2$$

cần cực tiểu hóa:

$$\sum_{i=1}^N (y_i - \mathbf{w}^T \mathbf{x})^2$$


Mô hình nhiễu với phân phối chuẩn/Gaussian  $\Leftrightarrow$  hàm loss trong linear regression

## Ví dụ 2: Linear regression

Bài toán hồi quy tuyến tính cho một tập dữ liệu  $D = \{\mathbf{X}, \mathbf{y}\}$

Chọn tiên nghiệm:

$$p(\mathbf{w}) = \mathcal{N}(\mathbf{w}|\mathbf{0}, \mathbf{I}\alpha^{-1})$$



tiên nghiệm cho  
 $\mathbf{w} \in \mathbb{R}^2$

## Ví dụ 2: Linear regression

Bài toán hồi quy tuyến tính cho một tập dữ liệu  $D = \{\mathbf{X}, \mathbf{y}\}$

tiền nghiệm:

$$p(\mathbf{w}) = \mathcal{N}(\mathbf{w} | \mathbf{0}, \mathbf{I}\alpha^{-1})$$

Hậu nghiệm và log hậu nghiệm:

$$p(\mathbf{w} | \mathcal{D}) \propto \mathcal{N}(\mathbf{0}, \mathbf{I}\alpha^{-1}) * \prod_{i=1}^N \mathcal{N}(\mathbf{w}^T \mathbf{x}_i, \sigma^2)$$

$$\log p(\mathbf{w} | \mathcal{D}) = -\frac{\alpha}{2} \mathbf{w}^T \mathbf{w} - \frac{1}{2\sigma^2} \sum_{i=1}^N (y_i - \mathbf{w}^T \mathbf{x}_i)^2 + \text{const}$$

## Ví dụ 2: Linear regression

Bài toán hồi quy tuyến tính cho một tập dữ liệu  $D = \{\mathbf{X}, \mathbf{y}\}$

tiên nghiệm:

$$p(\mathbf{w}) = \mathcal{N}(\mathbf{w} | \mathbf{0}, \mathbf{I}\alpha^{-1})$$

Hậu nghiệm và log hậu nghiệm:

$$p(\mathbf{w} | \mathcal{D}) \propto \mathcal{N}(\mathbf{0}, \mathbf{I}\alpha^{-1}) * \prod_{i=1}^N \mathcal{N}(\mathbf{w}^T \mathbf{x}_i, \sigma^2)$$
$$\log p(\mathbf{w} | \mathcal{D}) = \boxed{-\frac{\alpha}{2} \mathbf{w}^T \mathbf{w}} - \frac{1}{2\sigma^2} \sum_{i=1}^N (y_i - \mathbf{w}^T \mathbf{x}_i)^2 + \text{const}$$

L2 Regulariser

## Ví dụ 2: Linear regression

Bài toán hồi quy tuyến tính cho một tập dữ liệu  $D = \{\mathbf{X}, \mathbf{y}\}$

Yêu cầu dự đoán  $y^*$  từ một điểm dữ liệu  $\mathbf{x}^*$  mới.

Phân phối dự đoán:

$$p(y^*|\mathcal{D}, \mathbf{x}^*) = \int p(y^*|\mathbf{w}, \mathcal{D}, \mathbf{x}^*)p(\mathbf{w})d\mathbf{w}$$



## Ví dụ 2: Linear regression

Bài toán hồi quy tuyến tính cho một tập dữ liệu  $D = \{\mathbf{X}, \mathbf{y}\}$

Yêu cầu dự đoán  $y^*$  từ một điểm dữ liệu  $\mathbf{x}^*$  mới.

Phân phối dự đoán:

$$p(y^* | \mathcal{D}, \mathbf{x}^*) = \int p(y^* | \mathbf{w}, \mathcal{D}, \mathbf{x}^*) p(\mathbf{w}) d\mathbf{w}$$



**tích phân phức tạp  
(intractable)**

## Ví dụ 3: Logistic regression

Mô hình: xét các điểm dữ liệu  $(x, y)$  với  $y = 1$  hoặc  $0$

- Xác suất  $y$  thuộc lớp 1/0

$$p(y^{(i)} = 1|x^{(i)}) = \frac{1}{1 + e^{-w^T x^{(i)}}} = \sigma(w^T x^{(i)}) = h(x^{(i)})$$

$$p(y^{(i)} = 0|x^{(i)}) = 1 - h(x^{(i)})$$

## Ví dụ 3: Logistic regression

Mô hình: xét các điểm dữ liệu  $(x, y)$  với  $y = 1$  hoặc  $0$

- Likelihood của tập dữ liệu:


$$p(D|w) = \prod_{i=1}^N p(y^{(i)}|x^{(i)}) = \prod_{i=1}^N h(x^{(i)})^{y^{(i)}} (1 - h(x^{(i)}))^{1-y^{(i)}}$$

- Log likelihood của tập dữ liệu (= - cost function):

$$\log p(D|w) = \sum_{i=1}^N [y^{(i)} \log h(x^{(i)}) + (1 - y^{(i)}) \log(1 - h(x^{(i)}))]$$

# Ví dụ 3: Logistic regression


Dữ liệu:



# Ví dụ 3: Logistic regression

Cực đại hàm log khả năng:

$$w^* = \operatorname{argmax} \log p(D|w)$$




# Ví dụ 3: Logistic regression

Cực đại hàm log hậu nghiệm  
(maximum a posteriori):



$$w^* = \operatorname{argmax} \log p(w|D)$$

$$= \operatorname{argmax} \log [p(D|w)p(w)]$$

⇒ regularisation



## Ví dụ 3: Logistic regression



# Đối chiếu

## Suy luận Bayes (Bayesian approach)

Xác suất = cấp độ niềm tin (degree of belief)

VD: bác sĩ chẩn đoán 60% mắc bệnh

Xem dữ liệu là bằng chứng duy nhất và **hữu hạn**

## Suy luận Tần suất (Frequentist approach)

Xác suất = tần suất xảy ra của sự kiện

Xem dữ liệu như các mẫu lấy từ *vũ-trụ-dữ-liệu* **vô hạn**



# Các ưu điểm

- Khi xây dựng mô hình, các **kiến thức chuyên ngành/thông tin phụ trợ** có thể được đưa vào mô hình dưới dạng **tiên nghiệm**
  - **tiên nghiệm** có thể được biểu diễn qua **kiến trúc mạng**
  - <https://twitter.com/fchollet/status/1134947629576597504>
  - VD: CNN thiết lập prior về tính chất của ảnh 2D bằng cách sử dụng tầng convolution
- Kết quả cuối là phân phối xác suất  $\Rightarrow$  chứa thông tin về rủi ro/bất định
  - Quan trọng khi ra quyết định dựa theo mô hình (trong y tế, giao thông, pháp luật, v.v.)



François Chollet ✓  
@fchollet

About 10,000 deep learning papers have been written about "hard-coding priors about a specific task into a NN architecture works better than a lack of prior" -- but they're typically being passed as "architecture XYZ offers superior performance for [overly generic task category]"

5:19 AM · Jun 2, 2019 · [Twitter Web Client](#)

168 Retweets 740 Likes



# Các khuyết điểm


- Mathematical difficulty: phải xử lý các phép tích phân phức tạp.

Giải pháp:


- Các phương pháp ước lượng
- Các phép thử: *Markov Chain Monte Carlo (MCMC)*, *Gibbs*, *importance*, *Metropolis*, v.v
- Các phương pháp *variational*
- Cần chọn tiên nghiệm thích hợp

# Ứng dụng


- Địa lý thống kê



nguồn: Wikipedia



nguồn: gisgeography



nguồn: gisgeography

# Ứng dụng

- Địa lý thống kê
- Khí hậu học

## Prediction of Himalayan precipitation from short and fragmented records

Lead Supervisor: [Daniel Bannister](#), British Antarctic Survey

 NERC criteria apply

### Atmosphere, Ice, and Climate group

Rainfall in the Himalayas provides freshwater to over a billion people. However, highly localised extreme events can cause flash floods that devastate vulnerable local communities. Establishing the frequency of extreme events across the Himalayas is highly challenging, given the scarcity, reliability, and uneven distribution of rainfall observations. In this project, we aim to use a novel technique, called "patched kriging", to exploit all the information available from a network of short and fragmented rainfall measurements to produce a spatially homogenous dataset for the northwestern Himalayas. The result will be a reconstruction of annual maximum values of precipitation in ungauged/unobserved areas, demonstrating the reliability of this method for understanding the hydrometeorology of rainfall extremes in the Himalayas.

Taken



Links to relevant supporting information: [Libertino, A. et al. \(2018\). Regional-scale analysis of extreme precipitation from short and fragmented records. Advances in Water Resources, 112, 147-159.](#)

Duties of the student:

- Learn about rainfall observations and extreme precipitation events in the Himalayas
- Learn about statistical interpolation and [machine learning](#) methods for dealing with uneven and fragmented rainfall records
- Employ these tools to provide extreme rainfall estimates in ungauged/unobserved areas of the Himalayas
- Prepare a short report

Suggested timetable:

- Week 1: Welcome to BAS; literature review
- Week 2: Learn how to access, analyse, and visualise precipitation data
- Week 3: Learn about interpolation techniques and [machine learning](#) methods
- Weeks 4-8: Write and implement code to apply "patched kriging" to precipitation dataset
- Week 9-10: Write up summary; give short presentation to small group at BAS

nguồn: CUED UROP

# Ứng dụng

- Địa lý thống kê
- Khí hậu học
- Điều khiển - Tự động hóa
  - Kalman filter, particle filter

# Ứng dụng

- Địa lý thống kê
- Khí hậu học
- Điều khiển - Tự động hóa
  - Kalman filter, particle filter
- Khoa học cơ bản:
  - Sinh học tiến hóa: phát sinh chủng loại  
[https://en.wikipedia.org/wiki/Bayesian\\_inference\\_in\\_phylogeny](https://en.wikipedia.org/wiki/Bayesian_inference_in_phylogeny)
  - Hóa sinh phân tử: BATMAN (**BA**yesian **T**ool for **M**ethylation **AN**alysis)  
[https://en.wikipedia.org/wiki/Bayesian\\_tool\\_for\\_methylation\\_analysis](https://en.wikipedia.org/wiki/Bayesian_tool_for_methylation_analysis)
  - Phương pháp khoa học (scientific method)

# Ứng dụng

- Địa lý thống kê
- Khí hậu học
- Điều khiển - Tự động hóa
  - Kalman filter, particle filter
- Khoa học cơ bản:
  - Sinh học tiến hóa: phát sinh chủng loại
  - Hóa sinh phân tử: BATMAN (**BA**yesian **T**ool for **M**ethylation **AN**alysis)
  - Phương pháp khoa học (scientific method)
- Ra quyết định/Decision making:
  - Y tế
  - Luật pháp
  - Chính sách
  - v.v

# Ứng dụng: học máy xác suất

Naive Bayes Classifier

Bayesian Network

Dirichlet Latent allocation (LDA)

Variational Inference

Variational Auto-Encoder

$$p(C_k | x_1, \dots, x_n)$$

$$p(C_k | \mathbf{x}) = \frac{p(C_k) p(\mathbf{x} | C_k)}{p(\mathbf{x})}$$



$$p(C_k, x_1, \dots, x_n)$$

$$= p(x_1, \dots, x_n, C_k)$$

$$= p(x_1 | x_2, \dots, x_n, C_k) p(x_2, \dots, x_n, C_k)$$

$$= p(x_1 | x_2, \dots, x_n, C_k) p(x_2 | x_3, \dots, x_n, C_k) p(x_3, \dots, x_n, C_k)$$

$$= \dots$$

$$= p(x_1 | x_2, \dots, x_n, C_k) p(x_2 | x_3, \dots, x_n, C_k) \dots p(x_{n-1} | x_n, C_k) p(x_n | C_k) p(C_k)$$

Giả định "naive" về tính độc lập:  $p(x_i | x_{i+1}, \dots, x_n, C_k) = p(x_i | C_k)$

$$\begin{aligned} p(C_k | x_1, \dots, x_n) &\propto p(C_k, x_1, \dots, x_n) \\ &= p(C_k) p(x_1 | C_k) p(x_2 | C_k) p(x_3 | C_k) \dots \\ &= p(C_k) \prod_{i=1}^n p(x_i | C_k), \end{aligned}$$



# Ứng dụng: học máy xác suất

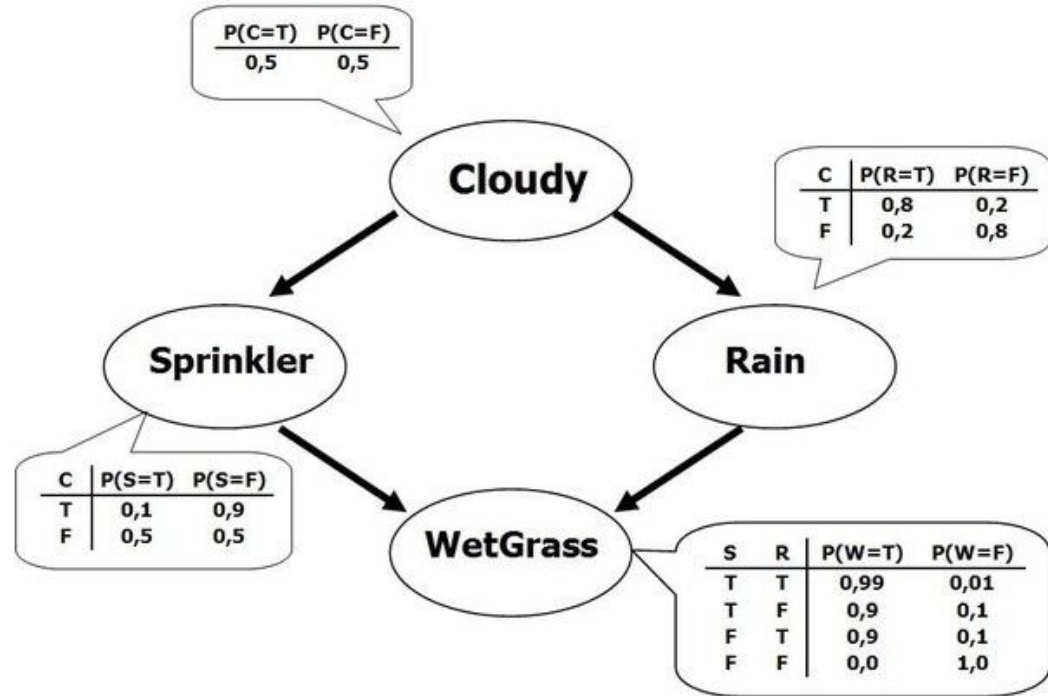
Naive Bayes Classifier

**Bayesian Network**

Dirichlet Latent allocation (LDA)

Variational Inference

Variational Auto-Encoder



# Ứng dụng: học máy xác suất

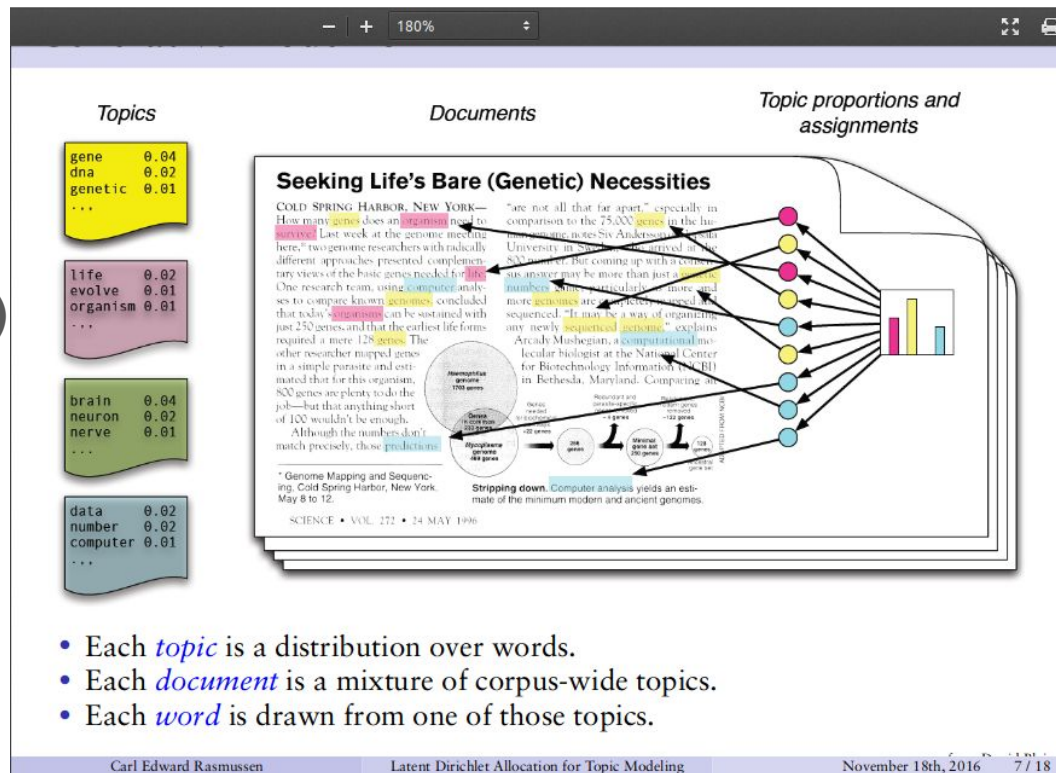
Naive Bayes Classifier

Bayesian Network

Dirichlet Latent allocation (LDA)

Variational Inference

Variational Auto-Encoder



# Ứng dụng: học máy xác suất

Naive Bayes Classifier


Bayesian Network

Dirichlet Latent allocation (LDA)

**Variational Inference**

Variational Auto-Encoder

## Variational Inference



- VI turns **inference into optimization**.
- Posit a **variational family** of distributions over the latent variables,

$$q(\mathbf{z}; \mathbf{v})$$

- Fit the **variational parameters**  $\mathbf{v}$  to be close (in KL) to the exact posterior.  
(There are alternative divergences, which connect to algorithms like EP, BP, and others.)

# Ứng dụng: học máy xác suất

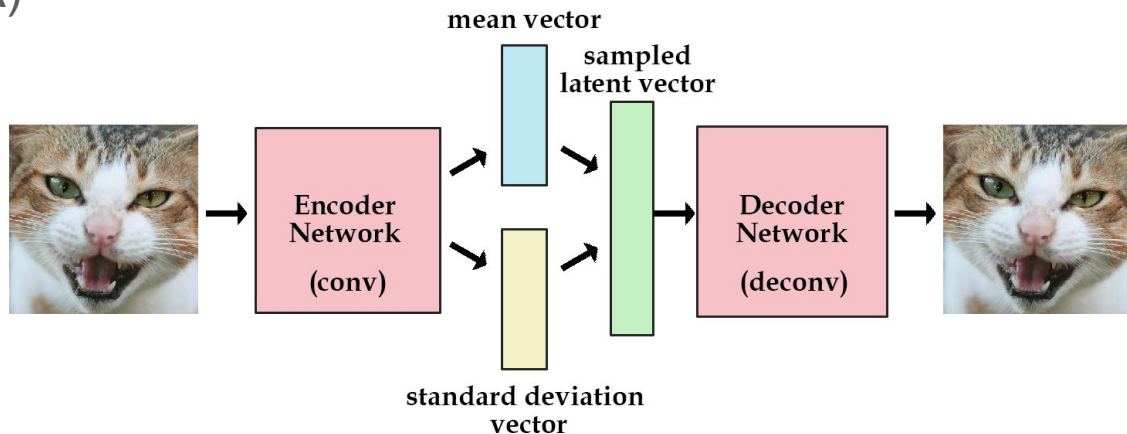
Naive Bayes Classifier

Bayesian Network

Dirichlet Latent allocation (LDA)

Variational Inference

**Variational Auto-Encoder**



# Các nguồn tham khảo

Pattern Recognition and Machine Learning, by Christopher Bishop

Information Theory, Inference, and Learning Algorithms, by David J.C. MacKay

<https://ben-lambert.com/bayesian-lectures/>

<http://kvfrans.com/variational-autoencoders-explained/>

<https://www.cs.jhu.edu/~jason/tutorials/variational.html>

<https://twitter.com/>